

STT ANNOTATSIYA STANDARTI

Audio-to-Text Ma'lumotlar Bazalari Yaratish uchun Rasmiy Qo'llanma

Versiya 1.2

Fevral 2026

1. KIRISH VA ASOSIY MAQSADLAR

1.1. UzDataLab Maqsadi

UzDataLab O'zbek tilidagi sun'iy intellekt texnologiyalari uchun sifatli, standartlashtirilgan va ilmiy asoslangan ma'lumotlar bazalarini yaratishga qaratilgan yetakchi tashkilotdir. Ushbu standart O'zbek tilida Speech-to-Text (STT) tizimlari uchun ma'lumotlar annotatsiyasining yagona qoidalarini belgilaydi.

1.2. Standartning Ahamiyati

Ushbu hujjat O'zbek tilida STT annotatsiyasining milliy standarti sifatida qabul qilinadi va quyidagi maqsadlarga xizmat qiladi:

AI modellarini aniqroq o'qitish - Yuqori sifatli datasetlar

Turli tashkilotlar tomonidan yaratilgan ma'lumotlarning bir xilligini ta'minlash - Standartlashtirish

O'zbek tilining raqamli rivojlanishini qo'llab-quvvatlash - Tilimizni himoya qilish

1.3. Qo'llanilish So'hasi

Ushbu standart quyidagi sohalarda qo'llaniladi:

Audio materiallarni matnga aylantirish (transkripsiya)

STT ma'lumotlar bazalarini yaratish

AI modellarini o'qitish uchun datasetlar tayyorlash

Davlat va xususiy sektor loyihalari

Tadqiqot va akademik ishlar

2. ASOSIY TAMOYILLAR

2.1. "Eshitilganidek" Tamoyili

Asosiy qoida: Spiker aytgan har bir tovush, pauza va nutqning barcha xususiyatlari matnga aks ettirilishi kerak.

2.2. Imlo Standartlari

Barcha matnlar O'zbek tilining zamonaviy imlo qoidalariga muvofiq yozilishi shart:

Vaziyat	Qoida	Misol
Tutuq belgisi	Har qanday holatda ham to'g'ri qo'llanilsin	'bolibdi' → 'bo'libdi'
O' va G' harflari	To'g'ri ishlatilsin	'ogir' → 'o'g'ir'
Qo'shma so'zlar	Defis bilan yozilsin	'ob havo' → 'ob-havo'
Apostroflar	Standart ' belgisi bilan	G`` → G',o`` → o'

3. SHEVALAR VA TALAFUZ

3.1. Sheva Qoidasi

Qoida: Har qanday shevada aytilgan so'zni audio eshitilgandek yozing. Adabiy tilga o'zgartirmang.

□ Sheva Turi	Audio Talaffuz	To'g'ri	Noto'g'ri
Toshkent	"Man borgan edim"	"Man borgan edim"	"Men borgan edim"
Farg'ona	"Keldim-a"	"Keldim-a"	"Keldim"
Samarqand	"Keldi"	"Keldi"	"Keldim"

Qoraqalpoq	"Min bardim"	"Min bardim"	"Men bordim"
------------	--------------	--------------	--------------

3.2. Talaffuz Transformatsiyasi

ASL AUDIO: "Man bugun maktabga bordim"

ASL MATN (agar mavjud): "Men bugun maktabga bordim"

TO'G'RI ANNOTATSIYA: "Man bugun maktabga bordim"

Sabab: Audio eshitilgandek yozish - asosiy tamoyil

4. FE'L SHAKLLARI VA MAZMUN

4.1. Mazmun Saqlash Tamoyili

ASOSIY QOIDA: Audio eshitilgandek yoziladi, lekin MAZMUN o'zgartirilmasligi kerak.

Holat	Qoida	Misol	Status
Qo'shimcha so'z (mazmun bir xil)	Audioga moslanadi	"bo'libdi" → "bo'lib ketibdi"	ACCEPT
Fe'l shakli o'zgargan (mazmun bir xil)	Audioga moslanadi	"bordi" → "borishdi"	ACCEPT
Shaxs/son o'zgargan (mazmun o'zgardi)	RED qilinadi	"bo'libdi" → "bo'libdilar"	REJECT
Fakt o'zgardi lekin ma'no saqlandi	Fakt audioga moslanadi	"uchta" → "ikki-ta"	☐ KORREKSIYA

4.2. Misollar va Tushuntirishlar

QABUL QILINADI:

Audio: "Bu yerdagi narsalar ostun-ustun bo'lib ketibdi"

Text: "Bu yerdagi narsalar ostun-ustun bo'libdi"

Natija: "Bu yerdagi narsalar ostun-ustun bo'lib ketibdi"

RAD ETILADI:

Audio: "Bu yerdagi narsalar ostun-ustun bo'libdilar"

Text: "Bu yerdagi narsalar ostun-ustun bo'libdi"

Natija: REJECT (mazmun o'zgardi)

5. RAQAMLAR VA MAXSUS BELGILAR

5.1. Raqamlarni Yozish Qoidasi

Qoida: Barcha raqamlar to'liq so'z shaklida yoziladi.

Raqam	To'g'ri Yozuv	Noto'g'ri
5	besh	5
1991	bir ming to'qqiz yuz to'qson bir	1991
\$50	ellik dollar	\$50
50%	ellik foiz	50%

5.2. Sanalar va Vaqtlar

To'g'ri: "o'n ikkinchi mart, ikki ming yigirma to'rt yil"

Noto'g'ri: "12.03.2024"

To'g'ri: "soat besh o'n besh da"

Noto'g'ri: "soat 5:15 da"

6. TINISH BELGILARI VA FORMATLASH

6.1. Asosiy Tinish Belgilari

Belgi	Qo'llanilishi	Misol
. (Nuqta)	Gap oxirida	"Men bordim."
, (Vergul)	Pauza joylarida	"Men bordim, u keldi."
? (So'roq)	Savol gaplarda	"Qachon kelding?"
! (Undov)	Hayajonli gaplarda	"Ajoyib!"
" " (Tirnoq)	To'g'ridan-to'g'ri nutq	U dedi: "Keling."
- (Defis)	Qo'shma so'zlarda	"ota-ona", "ob-havo"

6.2. Normalizatsiya Qoidalari

MUHIM: Barcha apostroflar standart ' belgisi bilan yozilishi kerak.

STANDARTLASHTIRISH:

Noto'g'ri: G``, O``, g``, o``

To'g'ri: G', O', g', o'

ASOS: STT modellari har xil apostroflarni har xil belgilar sifatida qabul qiladi.

7. MAXSUS TEGLAR VA ULARNING QO'LLANILISHI

7.1. Teglar Qo'llanilishi (Cheklangan)

MUHIM: Teglar faqat kerak bo'lganda, oz miqdorda qo'llaniladi.

□ Tag	Qachon Qo'llaniladi	Misol	Status
Teg qo'shilmaydi	Orqa fondagi shovqin, lekin audio aniq	"Men bordim" (shovqin bor)	NO TAG
[SHOVQIN]	Shovqin nutqni qoplaydi	"Men [SHOVQIN] bordim"	REJECT
[KULGI]	Kulgi tovushi (ixtiyoriy)	"U [KULGI] gapirdi"	OPTIONAL
[MUSIQA]	Musiqqa baland, nutqni qoplaydi	"[MUSIQA] gapirish mumkin emas"	REJECT

7.2. Qat'iy Qoidalar

Agar audio tushunarsiz bo'lsa - REJECT

Agar boshqa tilda bo'lsa - REJECT

[TUSHUNARSIZ] teg hech qachon qo'llanilmaydi

[BOSHQA_TIL] teg hech qachon qo'llanilmaydi

8. SIFAT NAZORATI SISTEMASI

8.1. Anotatorlar Me'yorlari

Ko'rsatkich	Talab	Izoh
Aniqlik (Accuracy)	Kamida 95%	Audiolarning 95% to'g'ri annotatsiya
Xatolik Darajasi	5% dan oshmasin	100 ta audiodan 5 tasi xato bo'lishi mumkin
Qayta O'qitish	3 ketma-ket xato	3 marta ketma-ket xato qilganda
Tezkorlik	Kompaniya belgilaydi	Har bir tashkilot o'z me'yorini belgilaydi

8.2. Nazorat Mexanizmlari

USHBU QO'LLANMADAN FOYDALANAYOTGANLAR UCHUN:

Tasodifiy Tekshiruv:

Har 100 ta audiodan 5 tasini tasodifiy tanlang

Ular "Gold Standard" (UzDataLab tasdiqlagan) bilan solishtiring

Aniqlik darajasini hisoblang

Haftalik Audit:

Har hafta annotatsiya sifatini tekshiring

Statistikani yuriting

Muammolarni aniqlang

UzDataLab Tool'lari:

Agar mavjud bo'lsa, tizim avtomatik tekshiradi

Har safar turli audiolar beriladi

9. RAD ETISH (REJECT) SISTEMASI

9.1. Majburiy Rad Etish Sabablari

Sabab Kodi	Tavsifi	Misol
------------	---------	-------

MAZMUN_BUZILGAN	Gapning ma'nosi o'zgardi	"keldi" → "kelmadi"
KOP_FARQ	3 yoki undan ko'p so'z farq	
FAKT_OZGARGAN	Faktik ma'lumot o'zgardi (son, ism, joy)	"Toshkent" → "Samarqand"
AUDIO_SIFATSIZ	Shovqinli, tushunarsiz, uzilgan	
BOSHQA_TIL	Audio o'zbek tilida emas	
YARIM_GAP	Gap to'liq aytilmagan, audio kesilgan	

9.2. Rad Etish Jarayoni (Ixtiyoriy)

QOIDA: Rad etish jarayoni har bir kompaniyaning ichki siyosatiga bog'liq.

TAVSIYA ETILGAN JARAYON:

- 1. Anotator rad sababini belgilaydi
- 2. Rad etilgan audio ma'lumotlar bazasidan chiqariladi
- 3. Sabablar statistikaga kiritiladi
- 4. Muammolar tahlil qilinib, yechim ishlab chiqiladi

10. RAGBATLANTIRISH VA MALAKA OSHIRISH

10.1. Ragbatlantirish Tizimi

Element	Tavsif	Izoh
Haftalik TOP-3	Eng yuqori sifatli ishlovchi anotatorlar	Jamoani rag'batlantirish
Bonus Tizimi	Yuqori aniqlik uchun qo'shimcha haq	Har bir kompaniya o'zi belgilaydi
Malaka Oshirish	Doimiy treninglar va seminarlar	Kamida oyda 1 marta

10.2. Sifat Ko'rsatkichlari

Ko'rsatkich	Maqsad	Hisoblash
Aniqlik (Accuracy)	95%+	$(\text{To'g'ri annotatsiyalar} / \text{Jami}) \times 100$
Yaroqlilik (Validity)	90%+	$(\text{Qabul qilingan audio} / \text{Jami}) \times 100$
Izchillik (Consistency)	98%+	Bir xil audio uchun bir xil natija

11. ALOQA VA QO'LLAB-QUVVATLASH

11.1. Texnik Yordam va Konsultatsiya

UzDataLab ushbu standartdan foydalanayotgan barcha tashkilotlarga quyidagi xizmatlarni taqdim etadi:

STT Annotatsiya Muammolari - Amaliy masalalar

Sifat Nazorati Tizimi - O'rnatish va sozlash

Annotatorlarni O'qitish - Trening va seminarlar

Datasetlar Audit - Sifatni tekshirish

11.2. Kontakt Ma'lumotlari

Telegram: @uzdatalabsupport

11.3. Murojaat Qilish Tartibi

Telegramda @uzdatalabsupport ga yozing

Muammoni batafsil tasvirlang (misollar bilan)

Kerak bo'lsa, audio namunalarni yuboring

Javobni 24 soat ichida oling